

Memoria Técnica Integrada del Sistema de Recuperación de Información

1. Introducción

Este documento integra la memoria técnica del sistema de recuperación de información y la documentación asociada a la evaluación gráfica de precisión-cobertura. El sistema se basa en técnicas de indexación inversa y modelos probabilísticos para ordenar documentos según su relevancia frente a consultas en lenguaje natural.

2. Modelos de Recuperación Implementados

Se emplean dos modelos principales: Divergence From Randomness (DFR-PL2) y Okapi BM25. Ambos incorporan mecanismos de normalización por longitud documental y ponderación probabilística de términos para mejorar la calidad de los resultados.

3. Estructuras de Datos y Optimizaciones

El sistema utiliza tablas hash para el almacenamiento eficiente de términos, estructuras de acumulación de puntuaciones y colas de prioridad para ordenar resultados. Se incorporan optimizaciones para evitar costes innecesarios de procesamiento y para corregir comportamientos matemáticos indeseados, como los IDF negativos.

4. Mejoras Introducidas

Entre las mejoras destacan la reformulación de los cálculos de peso probabilístico y la protección frente a valores negativos de IDF cuando un término aparece en más de la mitad de los documentos de la colección.


5. Evaluación Experimental

La evaluación se realizó sobre el corpus TIME utilizando 83 consultas. Se comparó el comportamiento de BM25 y DFR tanto con stemming de Porter como sin él mediante curvas interpoladas de precisión frente a cobertura.

6. Análisis de la Visualización Precisión-Cobertura

La gráfica de precisión-cobertura muestra cuatro curvas correspondientes a BM25 y DFR, con y sin stemming. Se observa que las configuraciones con stemming mantienen niveles de precisión superiores a lo largo de casi todo el rango de cobertura. Desde el punto de vista visual, la gráfica permite identificar tres conclusiones principales:

- Las curvas con stemming ocupan la envolvente superior del gráfico, indicando una mejor recuperación de documentos relevantes.
- La separación entre las curvas aumenta en niveles altos de cobertura, donde normalmente los sistemas sufren una pérdida de precisión más acusada.
- BM25 y DFR presentan comportamientos similares, aunque las diferencias sugieren que la normalización probabilística aplicada por cada modelo afecta de forma distinta a la recuperación de documentos largos.



La representación es adecuada porque utiliza el formato estándar de evaluación en Recuperación de Información: precisión interpolada en 11 puntos frente a recall. Esto facilita la comparación objetiva entre algoritmos y evidencia el impacto positivo del procesamiento morfológico mediante stemming. En conjunto, la visualización confirma la hipótesis planteada en la memoria técnica: la normalización probabilística y la reducción de variantes morfológicas contribuyen a mejorar simultáneamente precisión y cobertura.